

FASHION-MNIST

Classificação de peças de roupa com uma CNN estilo LeNet, comparada a dois baselines clássicos de Scikit-Learn.

APRESENTA

**Rafael Rocha
da Silva**

Reconhecer a categoria de uma peça de roupa a partir da imagem

ATRIBUTO -ALVO

categoria da peça – 10 classes

ATRIBUTOS PREDITIVOS

784 pixels (28×28, tons de cinza)

TIPO DA TAREFA

classificação multiclasse

Camiseta/top

Calça

Pulôver

Vestido

Casaco

Sandália

Camisa

Tênis

Bolsa

Bota

Fashion-MNIST, o substituto drop-in do MNIST clássico

70.000

IMAGENS NO TOTAL

60K / 10K


TREINO / TESTE

28×28

PIXELS, TONS DE CINZA

6.000

POR CLASSE (BALANCEADO)




Verificado, não assumido


VALORES AUSENTES	0 – tensor denso, ausência não é estruturalmente possível
DUPLICATAS	0 de 2.000 imagens verificadas
RÓTULOS INCONSISTENTES	0 fora do intervalo [0, 9]

Fashion-MNIST é um benchmark consolidado — não esperávamos achar problemas, mas conferimos explicitamente em vez de assumir.

Onde a separação entre classes já começa a aparecer



Calçados têm intensidade média bem menor — silhuetas pequenas, mais fundo preto.




PCA 2D (46,7% da variância) — calçados isolados; peças “de tronco” se sobrepõem.

Só o necessário — justificado item a item


NORMALIZAÇÃO	Z-score — média 0,2860 / desvio 0,3530
AUGMENTATION (SÓ TREINO)	recorte 2px + espelhamento horizontal
ESCALONAMENTO (BASELINES)	dispensável — pixels já numa escala única
VALORES EXTREMOS	0,06% de imagens atípicas — nenhuma removida
ATRIBUTOS IRRELEVANTES	1,4% dos pixels (cantos), variância ≈ 0 — mantidos

Validação escolhe; teste mede uma única vez



Estratificação (stratify=y) nos baselines. O conjunto de teste só é tocado uma vez, ao final — evitando vazamento de informação.

Dois baselines clássicos, pixel a pixel



Acurácia na validação. RandomForest venceu e seguiu para o teste (87,31%, F1 macro 0,8715) — cada pixel é tratado como atributo independente, sem noção espacial.


APRESENTA

Arthur de Azevedo Grazzia

Uma CNN estilo LeNet — ~420 mil parâmetros



Curvas de perda e acurácia por época



0,9062

ACURÁCIA VALIDAÇÃO

0,9024

ACURÁCIA TESTE

0,9011

F1 MACRO (TESTE)


Grid search de 24 combinações, na GPU

ESPAÇO DE BUSCA	<code>lr {2e-3, 1e-3, 5e-4} × dropout {0.2...0.5} × weight_decay {0, 1e-4}</code>
-----------------	---

CONFIGURAÇÃO VENCEDORA	<code>lr=0,002 · dropout=0,2 · weight_decay=0</code>
------------------------	--


HARDWARE	<code>Intel Arc B580 (XPU) · 24 comb. × 8 épocas + retreino de 15</code>
----------	--

A convolução supera os baselines; o ajuste refina mais




+2,9 p.p. da convolução sobre o melhor baseline · +1,8 p.p. adicionais do ajuste de hiperparâmetros.

Camisa é a classe mais difícil — recall 0,628



Camisa confunde principalmente com Camiseta/top e Pulôver.



Exemplos de erros — várias peças genuinamente ambíguas, mesmo pra um olho humano.

A arquitetura ainda tem margem

- CNN rasa — 2 blocos convolucionais, sem batch normalization, treinada por poucas épocas (10 a 15).
- O grid search melhora hiperparâmetros, mas a arquitetura em si poderia ser aprofundada.
- Maior ganho provável: separar melhor Camisa das demais peças “de tronco” (Camiseta/top, Pulôver, Casaco).
- Próximos passos: mais épocas com early stopping, batch normalization entre convoluções, arquitetura mais profunda.

Obrigado.

CNN + ajuste de hiperparâmetros: 92,04% de acurácia no teste do Fashion-MNIST — 4,7 p.p. acima do melhor baseline clássico.

github.com/4rth-g/fashion-mnist-fundamentos-ia